

C500 模型服务 API 交付文档 (CMI)

服务器地址: 172.26.63.11

部署日期: 2026-08-10

硬件环境: MetaX C500 × 8 (64GB/卡)

Docker 镜像: vllm-metax:0.19.0-maca.ai3.5.3.502 / sglang-metax:1.0.2-maca.ai3.5.3.208

一、服务列表

服务	模型	访问地址	GPU	状态	说明
主 LLM	Qwen3-30B-A3B-Instruct	http://172.26.63.11:8003	0,1	运行中	纯文本对话 (MoE 30B)
ASR	Qwen3-ASR-1.7B	http://172.26.63.11:8004	2	运行中	语音转文字
LLM-Omni	Qwen3-Omni-30B-A3B-Instruct	http://172.26.63.11:8006	3,4	部分运行	纯文本对话，多模态输入待激活

二、主 LLM 服务 (端口 8003)

2.1 模型信息

属性	值
模型名	qwen3-omni (对外名称)
真实架构	Qwen3MoeForCausalLM
参数量	30B (MoE, A3B 激活参数)
上下文长度	32,768 tokens
并行方式	2 卡张量并行 (GPU 0,1)
数据类型	bfloat16
能力	纯文本对话 (暂不支持音频/图像直接输入)

2.2 API 调用示例

cURL

查看模型列表

curl http://172.26.63.11:8003/v1/models

对话请求

```
curl http://172.26.63.11:8003/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "qwen3-omni",
  "messages": [
    {"role": "system", "content": "你是一个有用的 AI 助手。"},
```

```
    {"role": "user", "content": "请解释量子计算的基本原理"}
],
"max_tokens": 2048,
"temperature": 0.7,
"top_p": 0.9
}'
```

流式输出 (推荐)

```
curl http://172.26.63.11:8003/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "qwen3-omni",
  "messages": [{"role": "user", "content": "你好"}],
  "stream": true,
  "max_tokens": 512
}'
```

Python (OpenAI SDK)

```
from openai import OpenAI
```

```
client = OpenAI(
    base_url="http://172.26.63.11:8003/v1",
    api_key="not-needed" # 本地部署无需真实 API Key
)
```

非流式调用

```
response = client.chat.completions.create(
    model="qwen3-omni",
    messages=[
        {"role": "system", "content": "你是一个有用的 AI 助手。"},
        {"role": "user", "content": "请解释量子计算的基本原理"}
    ],
    max_tokens=2048,
```

```
temperature=0.7
)
print(response.choices[0].message.content)

# 流式调用 ( 推荐 )
stream = client.chat.completions.create(
    model="qwen3-omni",
    messages=[{"role": "user", "content": "写一首关于春天的诗"}],
    stream=True,
    max_tokens=1024
)
for chunk in stream:
    if chunk.choices[0].delta.content:
        print(chunk.choices[0].delta.content, end="", flush=True)
```

三、ASR 服务 (端口 8004)

3.1 模型信息

属性	值
模型名	qwen3-asr
参数量	1.7B
上下文长度	8,192 tokens
支持任务	语音转文字 (transcription)
GPU	GPU 2
镜像	vllm-metax:0.19.0-maca3.5.3-audio1 (自带音频支持)

3.2 API 调用示例

方式一：OpenAI 标准音频转录接口（推荐）

上传音频文件进行转录

```
curl http://172.26.63.11:8004/v1/audio/transcriptions \  
-F file=@/path/to/audio.wav \  
-F model=qwen3-asr
```

返回示例：

```
{"text": "你好，今天天气怎么样", "usage": {"type": "duration", "seconds": 3.5}}
```

方式二：Chat Completions 接口（文本测试用）

```
curl http://172.26.63.11:8004/v1/chat/completions \  
-H "Content-Type: application/json" \  
-d '{  
  "model": "qwen3-asr",  
  "messages": [{"role": "user", "content": "请把这段语音转写成文字"}],  
  "max_tokens": 256  
'
```

Python (OpenAI SDK)

```
from openai import OpenAI
```

```
client = OpenAI(  
    base_url="http://172.26.63.11:8004/v1",  
    api_key="not-needed"  
)
```

音频转录

```
with open("/path/to/audio.wav", "rb") as audio_file:  
    transcript = client.audio.transcriptions.create(  
        model="qwen3-asr",
```

```
        file=audio_file
    )
    print(transcript.text)
```

四、LLM-Omni 服务 (端口 8006)

4.1 模型信息

属性	值
模型名	default (SGLang 服务名)
真实架构	Qwen3OmniMoeForConditionalGeneration
参数量	30B (MoE, A3B 激活参数)
并行方式	2 卡张量并行 (GPU 3,4)
数据类型	bfloat16
能力	纯文本对话 (原生多模态输入待 SGLang 适配激活)

4.2 说明

- 该服务基于 **SGLang** 部署真正的 Qwen3-Omni-30B-A3B-Instruct 模型
- 当前 SGLang 1.0.2 版本已正确加载模型权重，但**音频/图像输入编码器未激活**
- 待沐曦/SGLang 官方更新适配后，可直接支持语音/图像直接输入，无需 ASR 中转
- **建议**：当前以 8003 为主服务，8006 为技术验证/备用服务

4.3 API 调用示例

查看模型信息

```
curl http://172.26.63.11:8006/model_info
```

文本对话

```
curl http://172.26.63.11:8006/v1/chat/completions \  
-H "Content-Type: application/json" \  
-d '{  
  "model": "default",  
  "messages": [{"role": "user", "content": "你好"}],  
  "max_tokens": 100  
'
```

五、语音对话完整流程

当前推荐的语音交互链路：

用户语音 → 8004 (ASR) → 文字 → 8003 (LLM) → 文字回复

↓

如需语音回复，后续补充 TTS

步骤说明： 1. 客户端录制音频（WAV 格式，16kHz 单声道） 2. 调用 POST

172.26.63.11:8004/v1/audio/transcriptions 获取文字 3. 将文字送入 POST

172.26.63.11:8003/v1/chat/completions 获取回复 4.（后续）通过 TTS 服务将回

复转为语音

六、JavaScript / 前端调用

// LLM 流式调用

```
const response = await fetch('http://172.26.63.11:8003/v1/chat/completions', {
```

```
method: 'POST',
headers: {
  'Content-Type': 'application/json',
  'Authorization': 'Bearer not-needed'
},
body: JSON.stringify({
  model: 'qwen3-omni',
  messages: [{role: 'user', content: '你好'}],
  stream: true,
  max_tokens: 512
})
});
```

// 处理 SSE 流式响应

```
const reader = response.body.getReader();
while (true) {
  const {done, value} = await reader.read();
  if (done) break;
  const chunk = new TextDecoder().decode(value);
  // 解析 SSE 数据
}
```

// ASR 音频上传

```
const formData = new FormData();
formData.append('file', audioBlob, 'recording.wav');
formData.append('model', 'qwen3-asr');
```

```
const asrResponse = await fetch('http://172.26.63.11:8004/v1/audio/transcription
s', {
  method: 'POST',
  body: formData
});
const asrResult = await asrResponse.json();
console.log(asrResult.text);
```


七、性能参数

参数	值
最大并发请求	16 (LLM 8003) / 8 (ASR 8004)
最大生成长度	32,768 tokens (LLM)
前缀缓存	已启用
推理模式	eager mode (稳定优先)